第二章
基礎機率及抽樣分配

關鍵字 (KEY WORDS)

- 機率
- 二項式分配
- 常態分配
- 中央極限定理



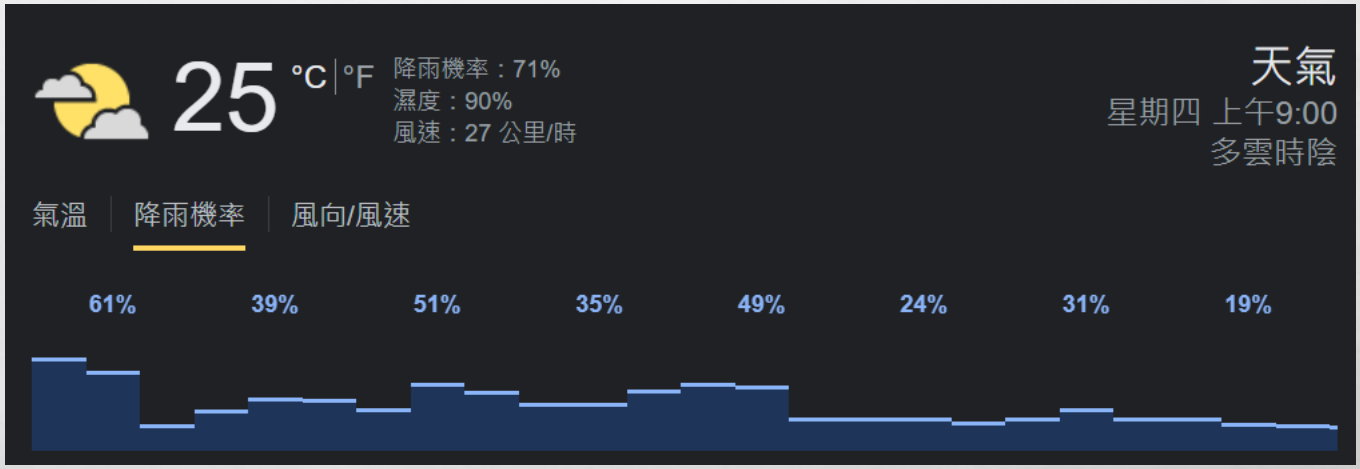
- 本章將介紹機率的基本概念、常見的機率分配，以及統計推論中常會用到的中央極限定理。

- 一個介於 0~1 之間的數值，用以描述一個隨機事件發生的可能性，數值愈大代表發生的可能性愈高，但不代表必定發生。

✓

機率概念

- 例如：吸菸已經被發現是心血管疾病重要危險因子之一，但是沒有吸菸並不意味不會得到心血管疾病，吸菸並不代表一定會得到心血管疾病。
- 例如 ： 降雨機率高不等於必定下雨，降雨機率與不降雨機率總和為 1



✔

機率應用

https://www.mohw.gov.tw/cp-4627-55770-1.htm



機率計算

- 下表為基隆地區心血管疾病調查資料，合計 61,963 人。(全基隆地區約有 37 萬人口數)
- 每日菸量 (X) 是一種**隨機變數** (RANDOM VARIABLE) 。
- 考量每日吸菸量是 0 、 1 包、 2 包、超過 2 包的事件，發生事件次數的比率 (PROPORTION) 就是 (樣本) 機率 (SAMPLE PROBABILITY) ，事件機率和為 1 。

表 2-1. 心血管疾病與吸菸量人數表
(每日菸量之邊際機率 MARGINAL PROBABILITY)

每日菸量 smoking (pack/day)	心血管疾病 (CVD)		
	無 (0)	有 (1)	合計
0 包	41,629	4,166	45,795
1 包	13,021	1,383	14,404
2 包	1,420	176	1,596
超過 2 包	144	24	168
合計	56,214	5,749	61,963

每日菸量 smoking (pack/day)	抽菸量的機率 (邊際機率) Probability of persons smoke pack of cigarettes per day
0 包	45,795/61,963
1 包	14,404/61,963
2 包	1,596/61,963
超過 2 包	168/61,963
合計	61,963/61,963

✗

聯合機率 (JOINT PROBABILITY)

- 研究多個隨機變數 (VARIABLES) 時，每個變項會有自己發生的機率 (邊際機率， MARGINAL PROBABILITY) ，同時考慮多個變項發生的機率稱為聯合機率 (JOINT PROBABILITY) 。

- 例如：每個人有每日菸量 (X) 及心血管疾病 (Y) 的兩個變項，隨機抽出的人在這兩個變項有各自的可能值，總共有 8 種組合 (COMBINATIONS) 的聯合機率，其中抽到菸量為 0 且 (AND) 沒有心血管疾病的人的聯合機率為 P(X=0,Y=0)=41,629/61,963 =0.6718 ，也是事件 “ X=0, Y=0” 發生次數的比率。

表 2-2. 心血管疾與吸菸量機率 (聯合機率及邊際機率)

每日菸量	心血管疾病		
	無 (0)	有 (1)	邊際機率
0 包	0.6718	0.0672	0.739
1 包	0.2101	0.0223	0.2325
2 包	0.0229	0.0028	0.0258
超過 2 包	0.0023	0.0004	0.0027
邊際機率	0.9072	0.0928	1.0000

機率分配 (PROBABILITY DISTRIBUTION)

- 主要可以分成離散型 (DISCRETE) 、連續型 (CONTINUOUS) 兩大類，其中離散型常用來描述質性 (QUALITATIVE) 資料或計數型 (COUNT) 資料 (類別 (CATEGORICAL) 資料) ，連續型則可以用描述身高、體重、血壓。

- 以下將介紹的運動統計學常用的分配包含
- (1) 離散型：**二項式分配**；
- (2) 連續型：**常態分配**。



二項式分配 (BINOMIAL DISTRIBUTION)

- 在離散型中，最簡單的型式是二元變項 (binary variable) 的隨機變數，表示事件只有兩種狀態，例如成功或失敗、疾病的有或無、存活或死亡、性別。
- 成功的機率以 p 表示，失敗的機率則為 1-p 。
- 例如人口中男女生比例相等，隨機抽樣時男女抽的機率皆為 0.5 ，隨機抽取五個樣本時

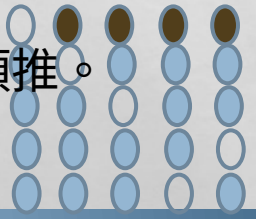


- 男生出現次數為的機率為

$$0.5 \times 0.5 \times 0.5 \times 0.5 \times 0.5 = 0.03125$$

- 男生出現 1 次可能發生在 5 次的任意其中一次，有 5 種可能，所以機率為 $\binom{5}{1}=5$

$$0.5 \times 0.5 \times 0.5 \times 0.5 \times 0.5 \times 0.5 = 0.15625$$



- 出現 2 次就會是任意 5 次取 2 次出現，會有 5 x 4 的可能，依此類推。

$$\binom{5}{2}=\frac{5!}{2!3!}=\frac{5\times4}{2}=10$$

二項式分配

- 所以如果重覆*N*次試驗，且每一次都是獨立的事件且成功機為*P*，代表成功次數的隨機變數(X)稱為二項式隨機變數(BINOMIAL RANDOM VARIABLE)。出現*X*次數的機率可以表示成

$$P(X = \mathrm{X}; p) = \binom{n}{x} p^{\mathrm{X}}(1-p)^{n-\mathrm{X}} = \frac{n!}{\mathrm{X}!\,(n-\mathrm{X})!} p^{\mathrm{X}}(1-p)^{n-\mathrm{X}},$$

稱為二項式分配(BINOMIAL DISTRIBUTION)。

- 此函數稱為**機率質量函數**(PROBABILITY MASS FUNCTION)。
-
- 上例中，男生出現次數為0的機率為$\binom{5}{0} 0.5^0(1-0.5)^{5-0}$
- 男生出現次數為1次的機率為$\binom{5}{1} 0.5^1(1-0.5)^{5-1}$
- 男生出現次數為2的機率為$\binom{5}{2} 0.5^2(1-0.5)^{5-2}$
- 二項式分布查表:
HTTPS://HOMEPAGE.DIVMS.UIOWA.EDU/~MBOGNAR/APPLETS/BIN.HTML

參數 (PARAMETER)

- 在統計學上稱 N 、 P 為二項式分配的參數 (PARAMETER) 。
- 實際上通常 N 是已知 (KNOWN) ， P 是未知的 (UNKNOWN) ，會藉由資料的收集來推估有興趣的參數 P 。
- 在前一章已經介紹平均數和變異數會搭配在一起以表達資料的集中趨勢和資料間分散差異的程度，不同的機率分配也可以利用平均值（ MEAN ）和變異數（ VARIANCE ）來表達同樣的特徵。



參數 (PARAMETERS)

- 二項式分配的
- **平均值**為$\sum_{x=0}^{n} xP(X=x;p) = \boldsymbol{np}$；
- **變異數**: $\sum_{x=0}^{n}(x-np)^2P(X=x\,;\,p) = \boldsymbol{np}\,(\mathbf{1}-\boldsymbol{p})$。

- 圖2-1、2-2顯示資料會集中於平均值附近，例如N=30的時候資料分別集中在$30 \times 0.5 = 15$和$30 \times 0.2 = 6$附近。此外，兩者的變異數分別為$30 \times 0.5 \times 0.5 = 7.5$和$30 \times 0.2 \times 0.8 = 4.8$，因為P=0.5的變異數較大，所以分配比較分散。

二項式分配機率質量函數的變化圖

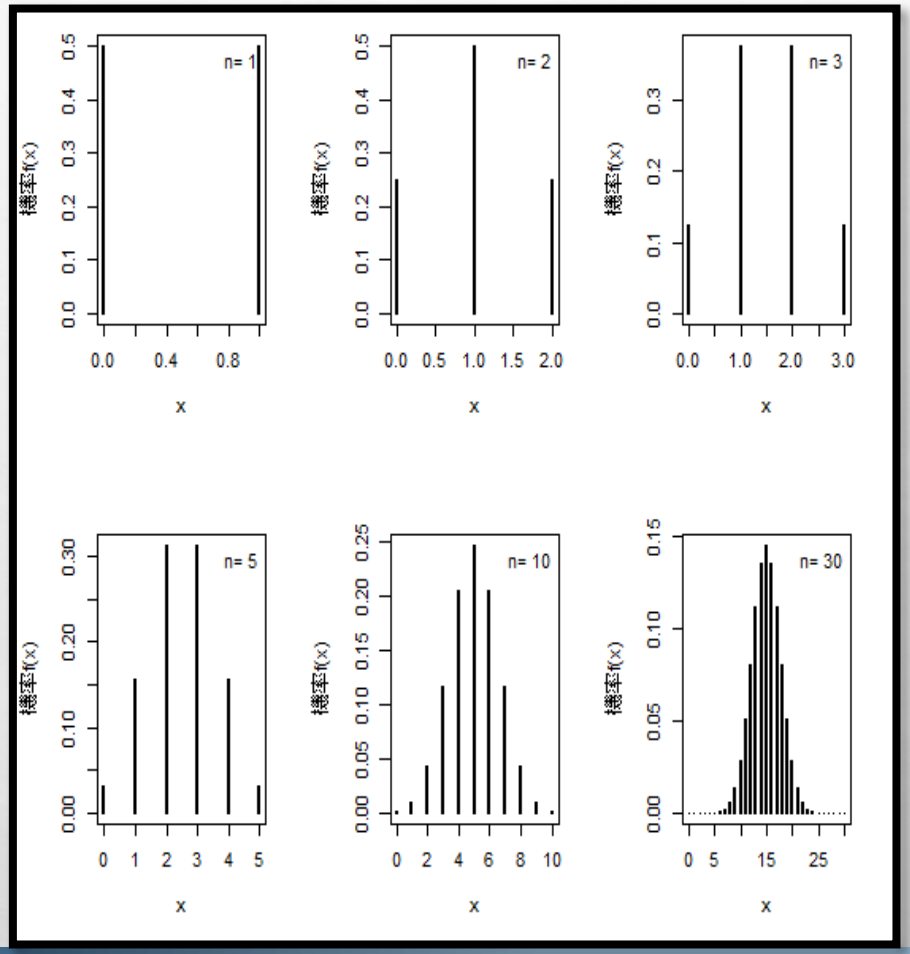


圖 2-1 二項式分配 p=0.5

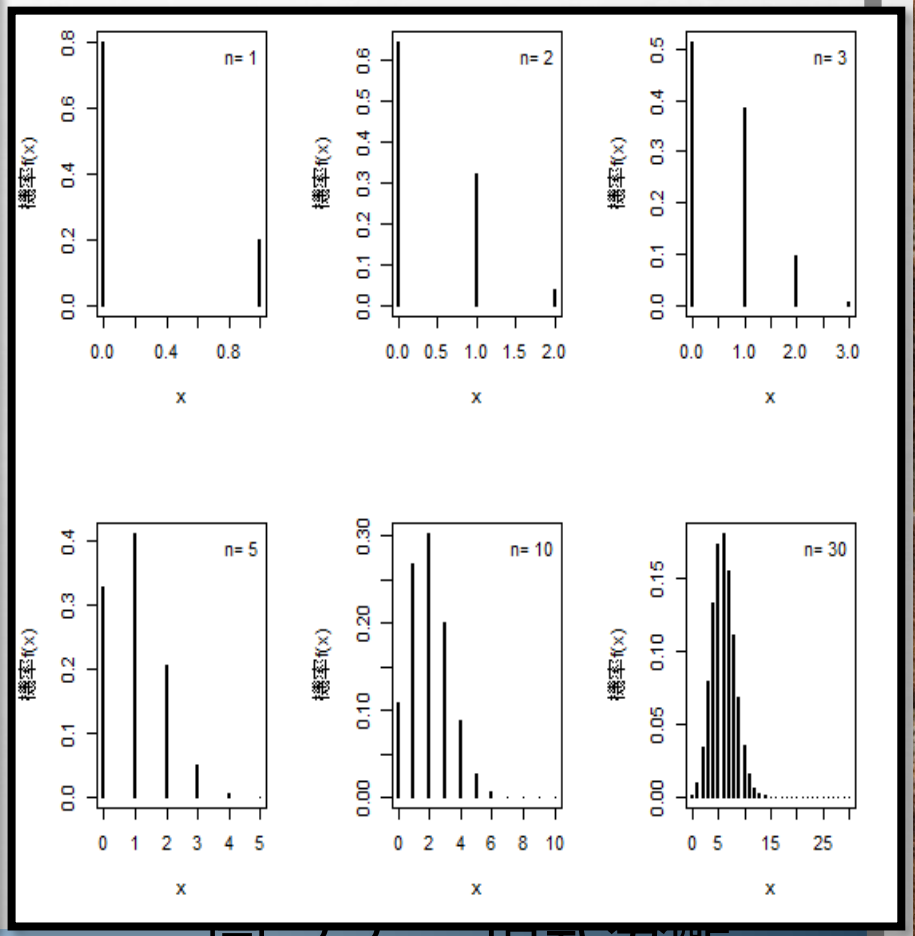
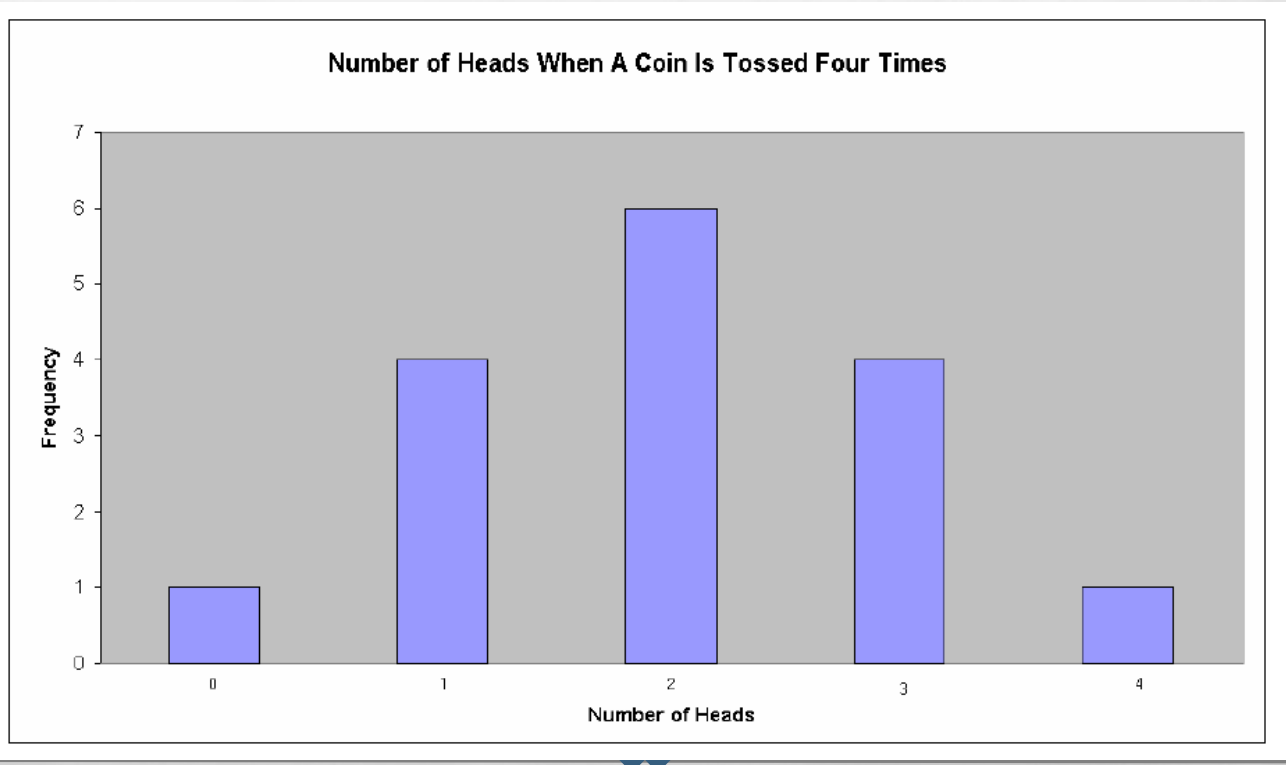


圖 2-2 二項式分配 p=0.2

例：擲銅板四次

Possible Outcomes of a coin flipped 4 times

0 Heads	1 Head	2 Heads	3 Heads	4 Heads
HHHH	HTTT	HHTT	HHHT	TTTT
	THTT	HTHT	HHTH	
	TTHT	HTTH	HTHH	
	TTTH	THHT	THHH	
		THTH		
		TTHH		



- **QUINCUNX: HTTPS://WWW.MATHSISFUN.COM/DATA/QUINCUNX.HTML**

- HTTPS://WWW.YOUTUBE.COM/WATCH?V=M8KZ6ZWHGDG

連續型隨機變數

- 連續型隨機變數常用來描述數值型資料，例如身高、體重、BMI。連續型分配的函數以**機率密度函數**(PROBABILITY DENSITY FUNCTION)稱之。
- 不同於離散型隨機變數，機率計算方式是利用積分方法求得，例如$\mathrm{P(A} \leq \mathrm{X} \leq \mathrm{B}) = \int_{\mathrm{A}}^{\mathrm{B}} f(x)dx$(面積)，且為了符合整體機率為1的性質，此函數必須滿足$\int_{\text{所有可能值}} f(x)dx = 1$。
- 另一個常見的名詞為**累積機率函數**(CUMULATIVE DISTRIBUTION FUNCTION)，是指小於等於該數值的機率，通常會以$F(x)$表示。

常態分配（NORMAL DISTRIBUTION）

- 又稱高斯分配 (GAUSSIAN DISTRIBUTION) ，是最常見的連續型分配，特色為分配會集中在平均值附近且左右對稱，外型有如一個鐘，屬於鐘形曲線 (BELL-SHAPED CURVE) 分配，而這特性並遍存在生活中的資料分佈。

- 圖 2-4 為 57,387 名基隆市無心血管疾病民眾收縮壓的分佈圖，平均值和標準差分別為 122 與 20 ，圖中虛線部份為平均值和標準差分別為 122 與 20 的常態分態，可以發現兩者分配非常相似，表示可以利用常態分配來描述無心血管疾病民眾的收縮壓。

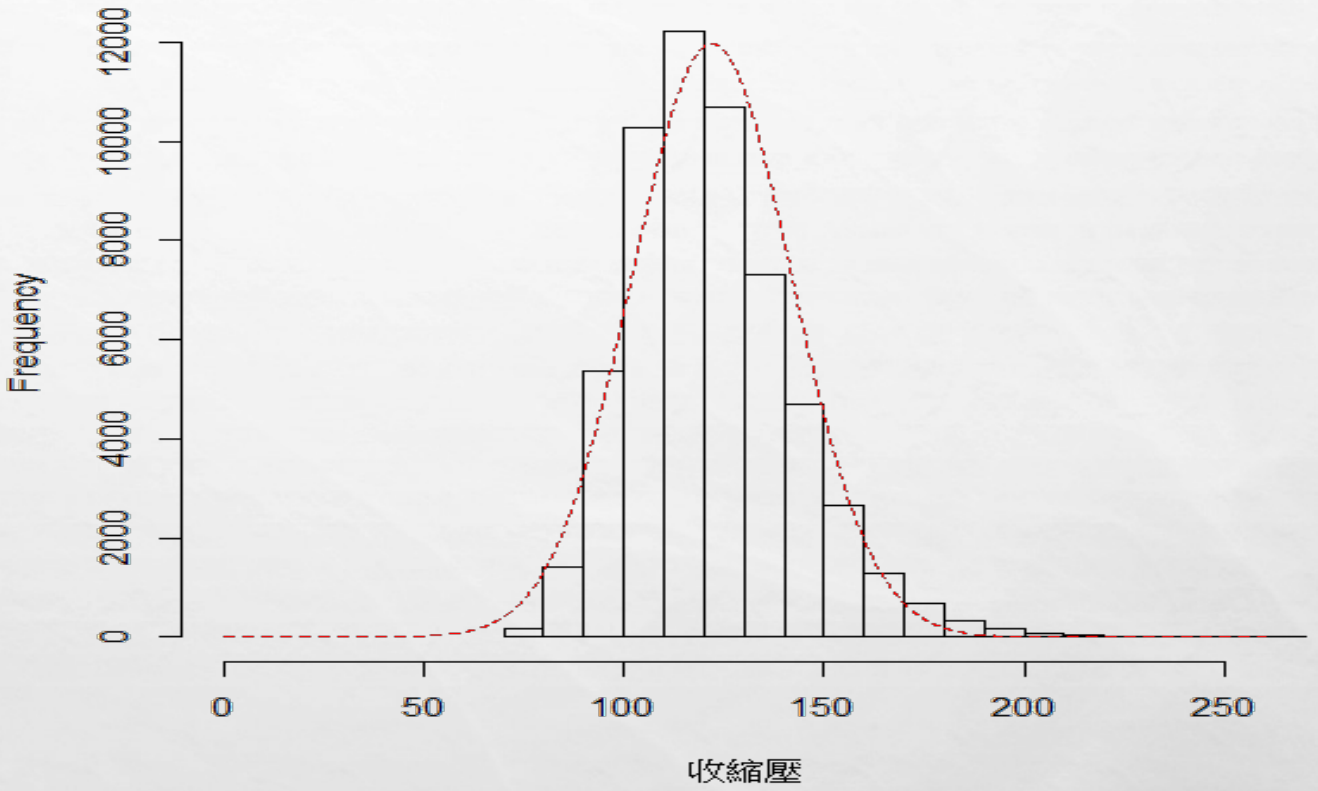


圖 2-4. 57,387 名無心血管疾病基隆市民收縮壓

常態分配（NORMAL DISTRIBUTION）

- 常態分配有兩個參數平均值與變異數(或標準差)，一般會以μ和σ^2(或σ)表示，其機率密度函數可以表示成：

$$f(x;\mu,\sigma^2)=\frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{1}{2\sigma^2}(x-\mu)^2},$$

$-\infty<x<\infty,-\infty<\mathrm{M}<\infty,$
$0<\Sigma^2<\infty$。

- 常態分配主要集中在平均值並以**平均值為中心對稱分佈，變異數會影響到整個分佈的形狀**，愈大時分配會愈扁平。

常態分配

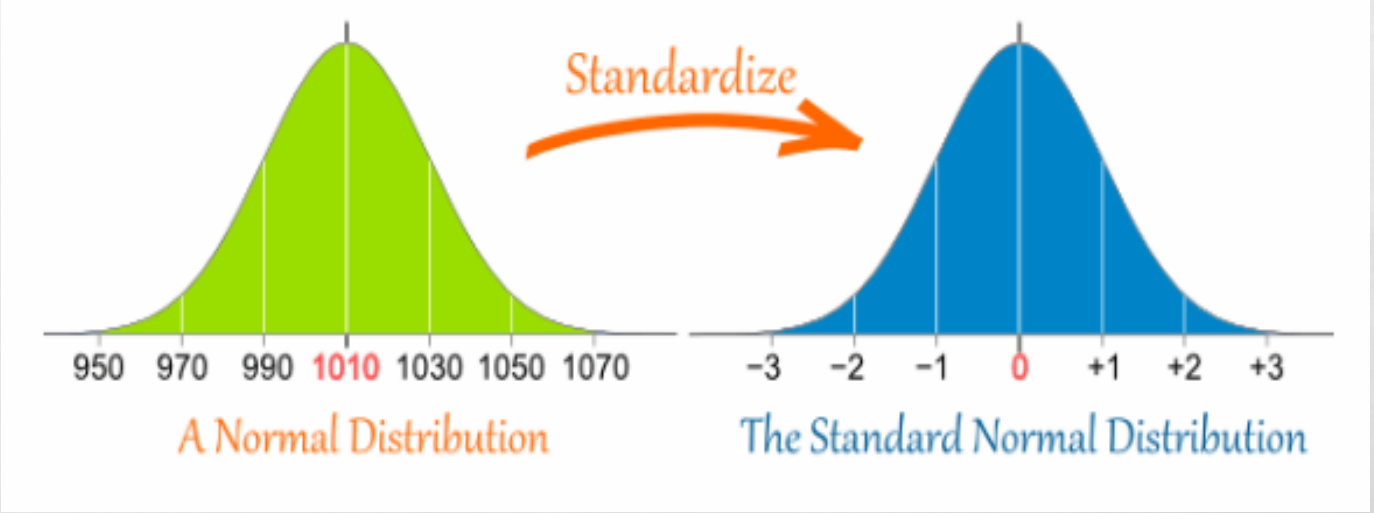
- **68%** of values are within **1 standard deviation** of the mean
- **95%** of values are within **2 standard deviations** of the mean
- **99.7%** of values are within **3 standard deviations** of the mean

- EXAMPLE: 95% OF STUDENTS AT SCHOOL ARE BETWEEN 1.1M AND 1.7M TALL. WHAT IS THE 99TH STUDENTS HEIGHT?

  - MEAN=(1.1+1.7)/2=1.4
  - STD=(1.7-1.1)/4=0.15
  - 99TH STUDENT IS AROUND 1.4+0.15*3=1.85

標準化

- 標準化 : (數値 - 平均値)/ 標準差



$$Z = \frac{X_i - \overline{X}}{S}$$

常態分配（NORMAL DISTRIBUTION）

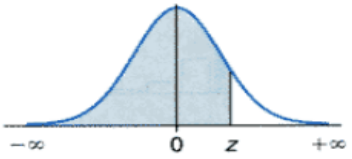
- 平均數為0且變異數為1的分配稱為**標準常態分配**(STANDARD NORMAL DISTRIBUTION)，通常會以Z分配表示，任何不同參數的常態分配隨機變數(X)減掉平均值除以標準差(STANDARD DEVIATION)會變成一個標準常態分配，
- $$Z=\frac{X-\mu}{\sigma}\sim N(0,1)$$，

此步驟稱為標準化(STANDARDIZE)，在計算常態分配的機率時，都會透過標準化步驟求得機率。

常態分配（NORMAL DISTRIBUTION）

- 由於常態分配之機率分布因計算不容易，通常會利用已計算好的標準常態分配表供大家查表求得機率，現在由於電腦計算的發達，不須再利用查表方式求得一個區間的機率，如， UNIV OF IOWA亦提供計算常態分配機率的功能。

常態累積機率表



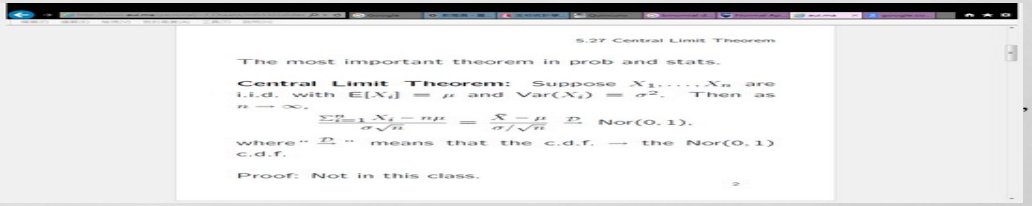
〔 課程目錄 | 回課程首頁 〕

連續隨機變數的機率值就是它的機率分配曲線與橫軸所圍的部份面積，亦即它的機率密度函數在部份範圍的積分值，通常都利用查表的方式配合簡單的計算來求常態分配的機率值。在使用上，不可能替每一個常態分配一個機率表，因而取一個常態分配為標準，以它的機率表求得所有常態分配的機率值，目前所有的常態分配表一律是取 $\mu=0$， $\sigma=1$的常態分配，稱此常態分配為標準常態分配。 P（Z＜z）為斜線部份的面積。

z	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
0.0	.5000	.5040	.5080	.5120	.5160	.5199	.5239	.5279	.5319	.5359
0.1	.5398	.5438	.5478	.5517	.5557	.5596	.5636	.5675	.5714	.5753
0.2	.5793	.5832	.5871	.5910	.5948	.5987	.6026	.6064	.6103	.6141
0.3	.6179	.6217	.6255	.6293	.6331	.6368	.6406	.6443	.6480	.6517
0.4	.6554	.6591	.6628	.6664	.6700	.6736	.6772	.6808	.6844	.6879
0.5	.6915	.6950	.6985	.7019	.7054	.7088	.7123	.7157	.7190	.7224
0.6	.7257	.7291	.7324	.7357	.7389	.7422	.7454	.7486	.7517	.7549
0.7	.7580	.7611	.7642	.7673	.7704	.7734	.7764	.7794	.7823	.7852
0.8	.7881	.7910	.7939	.7967	.7995	.8023	.8051	.8078	.8106	.8133
0.9	.8159	.8186	.8212	.8238	.8264	.8289	.8315	.8340	.8365	.8389
1.0	.8413	.8438	.8461	.8485	.8508	.8531	.8554	.8577	.8599	.8621
1.1	.8643	.8665	.8686	.8708	.8729	.8749	.8770	.8790	.8810	.8830

抽樣分配 (SAMPLING DISTRIBUTION)

- 雖然前述的機率分配可以協助大家描述資料的特徵，但是仍存在不少資料是無法利用常見的機率分配來表示的，使得必須要利用不同的方法來推論資料的性質，特別是最常被推論的母體平均值。
- **中央極限定理**(central limit theory)提供了一個替代方案，無須事先知道母體的分配，當抽樣n筆資料來自同一個分配且每一筆資料的抽樣過程都是獨立的，且此分配的平均值和標準差已知為μ和σ，**樣本數n夠大**時抽樣資料平均值會服從一個常態分配平均值為μ且標準差為$\sigma/\sqrt{n}$，所以經過標準化會變成標準常態分配。



- 很多種統計量的分配都可以用常用的機率分配來計算，但還有許多對生物統計分析重要的統計量的分配不知道如何計算？
- 中央集限定理說明若是統計量是可以寫成 “平均數” 的形態，則統計量的(抽樣)分配在樣本大時，可以用常態分配的公式計算 。
- 有些統計量不可以寫成 “平均數” 的形態，但他們的機率分配經常可用T分配，卡方(CHI-SQUARE) 或 F分配，或模擬的技術來計算 。目的通常是為 了計算尾部機率。
- HTTPS://YZHU.SHINYAPPS.IO/DS9DEVDATAPROD/

作業 (1)

1. 下表為某城市母體的抽菸與肺癌的人口統計表，今有一研究者在此母群體抽樣欲探討肺癌與吸菸的關係。

吸菸習慣	肺癌		
	無	有	合計
無	7970	30	8000
有	1980	20	2000
合計	9950	50	10000

(1) 若隨機抽樣一名，這個人有抽菸習慣的機率為何？

(2) 隨機抽到有抽菸習慣且沒有肺癌的人機率為何？

(3) 已知隨機抽到一名有抽菸習慣者，請問此人有肺癌的機率為何？

作業 (2)

2. 若運動選手暴露在過強的訓練下，下一個月發生運動傷害的機率為 0.2 ，某研究讓 30 各選手暴露在過強運動訓練下。

(1) 此研究一個月後有 3 位選手發生運動傷害的機率為何？

(2) 一個月後得到運動傷害的選手個數的平均值和變異數為何？

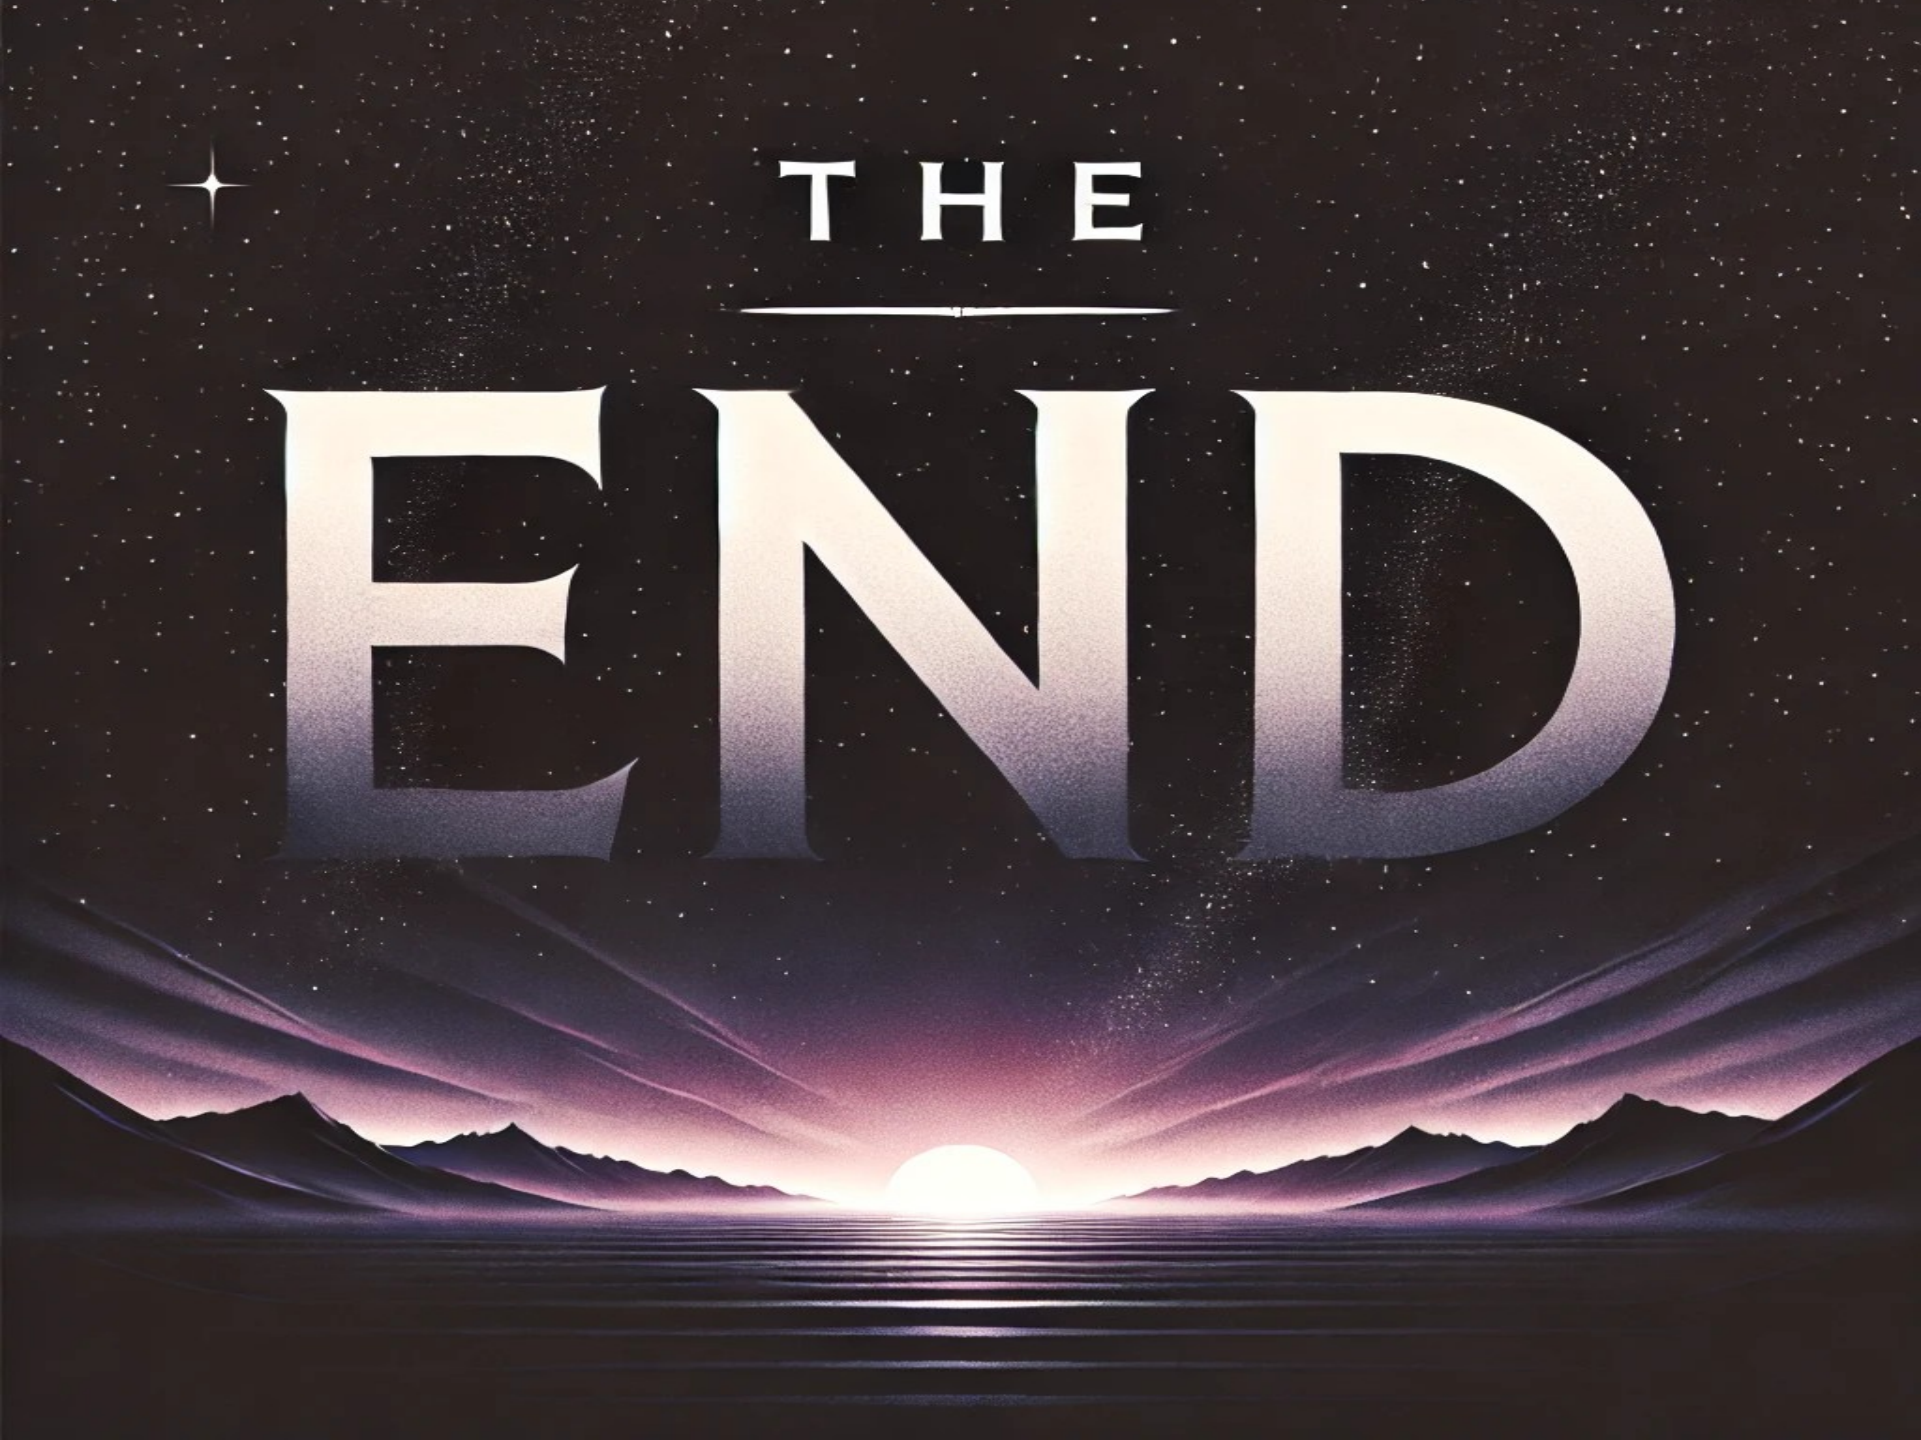


作業 (3)

4. 某研究抽樣 40 人，已知母體平均身高為 170 公分，標準差為 10 公分。

(1) 請問此 40 人的樣本平均數近似於什麼分配，此分配的平均值與標準差為何？

(2) 此 40 人平均身高超過 175 的機率為何？


THE
END